



EDUCACIÓN

IA

DATOS

Comparación de Técnicas de Aprendizaje Maquinal sobre Dataset del ICFES

Clasificación de estudiantes en quintiles de desempeño académico utilizando variables socioeconómicas e institucionales

Angel David Gomez Pastrana

angomezp@unal.edu.co

Leidy Yulliana Quiñones Gonzalez

lquinonesg@unal.edu.co

Contexto del Problema

Las pruebas ICFES Saber 11 representan un pilar fundamental en el sistema educativo colombiano, evaluando el desempeño académico de los estudiantes de educación media y sirviendo como requisito de ingreso a la educación superior.

A lo largo de los años, su evolución ha generado volúmenes masivos de datos que van más allá del rendimiento académico, abarcando variables demográficas, socioeconómicas e institucionales. Esta riqueza de información ofrece una oportunidad única para comprender los factores que influyen en los resultados educativos.

Generación Masiva
Gran volumen de datos
nacionales

Impacto en Políticas

Informan decisiones y mejoras
educativas

Evaluación Estándar

Mide competencias clave de
estudiantes

Este proceso de evaluación continua y recolección de datos alimenta la investigación para mejorar las estrategias educativas y la equidad académica en el país.



META



ANÁLISIS



MACHINE LEARNING

Objetivo

El objetivo general de esta investigación es **comparar algoritmos de clasificación supervisada** para determinar el quintil en el que se encuentra un estudiante en base a sus condiciones socioeconómicas.

Entrada

Variables socioeconómicas e institucionales del ICFES

Proceso

Modelos de Aprendizaje Automático y algoritmos de clasificación

Salida

Clasificación en quintiles de desempeño académico

Este enfoque permitirá identificar los modelos más eficientes para el análisis de datos educativos y la formulación de políticas públicas informadas.



IA



DATOS



MODELOS


Aprendizaje Automático

El Aprendizaje Automático (Machine Learning) es una rama de la Inteligencia Artificial que permite a los sistemas aprender y mejorar automáticamente a partir de la experiencia, sin ser explícitamente programados.



Entrada de datos

Recolección y limpieza de datos.




Preprocesamiento

Transformar y normalizar características.



Entrenamiento

Ajustar el modelo con los datos.



Predicción

Generar y evaluar resultados.

Este proceso iterativo permite a las máquinas adaptarse y mejorar su rendimiento con el tiempo, haciendo del Aprendizaje Automático una herramienta fundamental para resolver problemas complejos y extraer valor de grandes volúmenes de información.

Aprendizaje Supervisado



Datos etiquetados

Cada ejemplo incluye una entrada y su respuesta correcta para entrenar el modelo.

Dentro del aprendizaje supervisado, dos tareas principales son la **clasificación** y la **regresión**:



Aprende patrones

El algoritmo observa relaciones entre variables y ajusta sus predicciones.



Generaliza

Aplica lo aprendido a nuevos casos para clasificar o estimar resultados.



Ejemplo de datos etiquetados

Entrada: características del estudiante

Etiqueta: quintil de desempeño académico



Entradas

Datos de estudio, asistencia y resultados previos.




Etiquetas

Categorías conocidas para supervisar el aprendizaje.

Metodología General

La implementación de un sistema de clasificación supervisada sigue un proceso estructurado para asegurar la robustez y eficacia del modelo, desde la preparación de los datos hasta su evaluación final.



Cada fase es crucial para la construcción de un modelo predictivo fiable que pueda informar decisiones educativas con alta precisión.

Dataset ICFES

Para esta investigación, se utilizó un conjunto de datos real proporcionado por el Instituto Colombiano para la Evaluación de la Educación (ICFES), correspondiente a las pruebas Saber 11.

Este dataset fue procesado cuidadosamente para extraer variables clave que permiten comprender el contexto educativo de los estudiantes y su desempeño.



Variables Familiares

Composición del hogar, número de hermanos y tipo de vivienda.



Variables Socioeconómicas

Ingresos familiares, acceso a servicios públicos y nivel educativo de los padres.



Variables Institucionales

Tipo de colegio, ubicación y recursos educativos disponibles.



Quintiles de Desempeño

Variable objetivo que segmenta el rendimiento académico en cinco niveles.

Objetivo de clasificación

El objetivo principal fue clasificar a los estudiantes en cinco quintiles de desempeño académico, desde el más bajo (quintil 1) hasta el más alto (quintil 5).

EVALUACIÓN

CLASIFICACIÓN

REGRESIÓN

Métricas de Evaluación



Accuracy

Proporción de predicciones correctas sobre el total de casos. Ideal para datasets balanceados.



F1-Score

Equilibra precisión y recall. Especialmente útil cuando las clases están desbalanceadas.



ROC-AUC

Mide la capacidad discriminadora del modelo a través de distintos umbrales de decisión.



MAE

Promedio del error absoluto. Robusto frente a valores atípicos en problemas de regresión.



RMSE

Penaliza con mayor fuerza los errores grandes. Útil cuando importa más minimizar desviaciones severas.



Clasificación

Accuracy, F1-Score y ROC-AUC ayudan a evaluar modelos que predicen clases o categorías.



Regresión

MAE y RMSE permiten medir la distancia entre valores reales y predichos en variables numéricas.



Selección inteligente

La mejor métrica depende del problema, del tipo de error y del equilibrio entre precisión y robustez.

Random Forest

El algoritmo **Random Forest** es un método de aprendizaje conjunto (ensemble learning) que combina la potencia de múltiples árboles de decisión para mejorar la precisión y robustez de las predicciones. Funciona construyendo una multitud de árboles de decisión durante el entrenamiento y generando la clase que es el modo de las clases (clasificación) o la predicción media (regresión) de los árboles individuales.


La clave de su efectividad reside en dos mecanismos principales:

Bagging (Bootstrap Aggregating)

Cada árbol de decisión en el bosque se entrena con una muestra diferente del conjunto de datos original, seleccionada con reemplazo. Esto introduce aleatoriedad y diversidad entre los árboles.

Selección Aleatoria de Características

Durante la construcción de cada árbol, en cada nodo, solo se considera un subconjunto aleatorio de características para encontrar la mejor división. Esto reduce la correlación entre los árboles, haciéndolos más independientes.



Esta arquitectura de "sabiduría de las masas" permite que Random Forest sea excepcionalmente efectivo para problemas de clasificación multiclase, como la predicción de quintiles de desempeño académico, gracias a sus ventajas inherentes:

Robustez
Menos sensible al ruido en los datos y a los valores atípicos que los árboles individuales.

Reducción de Varianza
Al promediar las predicciones de árboles diversos, se reduce el sobreajuste y se mejora la generalización.

Manejo de No-linealidades
Capaz de modelar relaciones complejas y no-lineales entre las características y la variable objetivo.

Random Forest destaca por ofrecer un equilibrio entre rendimiento y resistencia a los problemas comunes del Machine Learning, siendo una opción robusta para predecir el quintil de desempeño académico de los estudiantes del ICFES.

Configuración de Random Forest

La optimización de los hiperparámetros es crucial para maximizar el rendimiento de un modelo Random Forest. Los siguientes parámetros fueron ajustados cuidadosamente para encontrar el equilibrio óptimo entre la capacidad de generalización y la prevención del sobreajuste en nuestro problema de clasificación de quintiles académicos.

Parámetro	Valor	Función	Justificación
PROFUNDIDAD Max Depth	20	Define la máxima profundidad de cada árbol de decisión en el bosque.	Un valor de 20 permite a los árboles capturar patrones complejos sin volverse excesivamente específicos para los datos de entrenamiento, evitando el sobreajuste.
CARACTERÍSTICAS Max Features	SQRT	Número de características a considerar para la mejor división en cada nodo.	Utilizar la raíz cuadrada (sqrt) de las características disponibles fomenta la diversidad entre los árboles y reduce la correlación, mejorando la robustez del bosque.
HOJAS Min Samples Leaf	4	Cantidad mínima de muestras requeridas para formar un nodo hoja.	Con un mínimo de 4 muestras por hoja, el modelo evita aprender de instancias muy pequeñas, lo que suaviza el modelo y lo hace menos sensible al ruido en los datos.
DIVISIÓN Min Samples Split	5	Cantidad mínima de muestras requeridas para dividir un nodo interno.	Un umbral de 5 asegura que las divisiones se realicen solo en nodos con suficiente información, lo que contribuye a la estabilidad y generalización del modelo.
BOSQUE N Estimators	400	Número de árboles de decisión en el bosque.	Un bosque con 400 árboles proporciona una gran cantidad de "opiniones" individuales, lo que lleva a predicciones más estables y precisas sin un aumento desproporcionado en el tiempo de cómputo.

Equilibrio de profundidad

Max Depth controla el tamaño de cada árbol para capturar patrones complejos sin sobreajustar.

Diversidad del bosque

Max Features usa sqrt para reducir la correlación entre árboles y aumentar la robustez.

Estabilidad y generalización

Min Samples Leaf, Min Samples Split y N Estimators suavizan el modelo y mejoran la confiabilidad.

La adecuada sintonización de estos hiperparámetros permite que el modelo Random Forest explore el espacio de características de manera eficiente, optimizando su capacidad para predecir los quintiles de desempeño académico con alta precisión y confiabilidad.

XGBoost: Elevando la Precisión con Boosting


XGBoost (Extreme Gradient Boosting) es una potente implementación del algoritmo de Gradient Boosting que ha demostrado ser excepcionalmente eficaz en diversos problemas de Machine Learning. Su poder reside en un enfoque de aprendizaje secuencial, donde cada nuevo árbol de decisión busca corregir los errores cometidos por los árboles construidos previamente.

Ventajas Clave de XGBoost



Regularización Integrada

Incorpora términos de regularización L1 y L2 para prevenir el sobreajuste, optimizando la complejidad del modelo.



Eficiencia Computacional

Optimizado para velocidad y rendimiento, con paralelización del árbol y manejo eficiente de la memoria.



Manejo de Desequilibrio

Especialmente robusto con conjuntos de datos desbalanceados, ideal para clases con baja frecuencia de aparición.



Rendimiento Superior

Frecuentemente supera a Random Forest en precisión, especialmente en escenarios complejos y de alta dimensionalidad.



XGBoost combina múltiples modelos débiles en uno fuerte, corrigiendo errores iterativamente.



Ideal para predicción de quintiles de desempeño académico, donde se requiere alta precisión en la clasificación multiclase.

La capacidad de XGBoost para combinar múltiples modelos débiles en uno fuerte, corrigiendo errores iterativamente y con robustas técnicas de regularización, lo hace una elección excelente para la predicción de quintiles de desempeño académico, donde se requiere alta precisión en la clasificación multiclase.

Configuración de XGBoost para Máxima Precisión

Para el modelo XGBoost, se realizó una cuidadosa selección y ajuste de hiperparámetros con el fin de optimizar su rendimiento en la clasificación de quintiles académicos.



Learning Rate 0.1

Controla el tamaño de cada paso en el proceso de boosting. Un valor de 0.1 permite un aprendizaje más estable y evita actualizaciones demasiado agresivas.

Se eligió este valor porque ofrece un buen equilibrio entre velocidad de aprendizaje y capacidad de generalización.



N Estimators 300

Indica el número total de rondas de boosting, es decir, cuántos árboles se construyen secuencialmente para refinar las predicciones.

Se escogió 300 para dar al modelo suficiente iteración para aprender patrones complejos manteniendo un ajuste controlado.



Max Depth 15

Define la profundidad máxima de cada árbol y, por tanto, su nivel de complejidad. Profundidades mayores capturan relaciones más detalladas en los datos.

Se seleccionó 15 para permitir suficiente expresividad sin limitar en exceso la capacidad predictiva del modelo.



Subsample 0.6

Determina qué proporción de los datos se usa en cada iteración de entrenamiento. Reduce la correlación entre árboles y mejora la robustez.

Se fijó en 0.6 para introducir diversidad entre iteraciones y disminuir el riesgo de sobreajuste.



XGBoost combina múltiples modelos débiles en uno fuerte, corrigiendo errores iterativamente.



Esta configuración busca el mejor equilibrio entre precisión, estabilidad y generalización para predecir quintiles de desempeño académico.

Resumen de ajuste


La sintonización precisa de estos hiperparámetros es fundamental para asegurar que el modelo XGBoost no solo alcance una alta precisión, sino que también mantenga una excelente capacidad de generalización a datos no vistos, evitando el sobreajuste y el subajuste para predecir los quintiles de desempeño académico.

CatBoost: Potencia y Precisión con Variables Categóricas

CatBoost (Categorical Boosting) es un algoritmo de Gradient Boosting diseñado específicamente para manejar variables categóricas de forma eficiente y nativa. A diferencia de otros modelos que requieren preprocesamiento intensivo como One-Hot Encoding, CatBoost integra el tratamiento de estas variables directamente en su proceso de entrenamiento, lo que lo hace excepcionalmente robusto para datasets con alta dimensionalidad y características cualitativas.


Sus principales innovaciones incluyen el **Manejo Nativo de Variables Categóricas** y el **Ordered Boosting**, que reducen el sesgo y mejoran la generalización del modelo.

Características Clave de CatBoost



Manejo Nativo de Categóricas

Transforma variables categóricas en valores numéricos "on-the-fly" usando estadísticas basadas en el target, evitando la explosión dimensional y el sobreajuste que causan técnicas como One-Hot Encoding.



Ordered Boosting


Implementa una técnica de boosting ordenada que previene el sesgo de la estimación de gradientes, reduciendo significativamente el sobreajuste y mejorando la capacidad de generalización del modelo.



Árboles Simétricos


Construye árboles de decisión balanceados con splits simétricos, lo que facilita la paralelización, acelera el entrenamiento y mejora la interpretabilidad del modelo.

Comparativa con Otros Algoritmos de Boosting



RANDOM FOREST

- FÁCIL DE USAR, ROBUSTO
- MENOS PROPENSO A SOBREAJUSTE



XGBOOST

- EXTREMADAMENTE RÁPIDO Y EFICIENTE
- EXCELENTE PARA DATOS TABULARES



CATBOOST

- MANEJO NATIVO DE VARIABLES CATEGÓRICAS
- EXCELENTE PRECISIÓN CON POCO AJUSTE

Como se observa, CatBoost se distingue por su enfoque especializado en datos categóricos, lo que lo posiciona como una herramienta invaluable para ciertos tipos de datasets.

Ventajas para el Dataset ICFES



Ideal para Datos Socioeconómicos

La capacidad de manejar variables categóricas de forma nativa lo hace perfecto para datos educativos y socioeconómicos, como los del ICFES, que a menudo contienen muchas características nominales u ordinales.



Reducción de Sobreajuste

Ordered Boosting minimiza el riesgo de que el modelo se ajuste demasiado a los datos de entrenamiento, asegurando una mejor generalización a nuevos datos.



Menos Ajuste de Hiperparámetros

Con menos parámetros críticos que ajustar, CatBoost facilita el proceso de optimización del modelo, lo que ahorra tiempo y recursos computacionales.

La especialización de CatBoost en el manejo de variables categóricas, junto con sus mecanismos para prevenir el sobreajuste, lo convierte en una opción potente y eficiente para predecir los quintiles de desempeño académico en el dataset ICFES, extrayendo el máximo valor de la rica información cualitativa.

CatBoost: La elección óptima para los datos socioeconómicos del ICFES

CatBoost destaca por manejar variables categóricas de forma nativa y por reducir el sobreajuste, logrando predicciones precisas y confiables para la clasificación de quintiles de desempeño académico.



Manejo nativo de
categóricas

Procesa variables cualitativas sin
depender de codificaciones extensas.



Menos sobreajuste

Ordered Boosting mejora la
generalización y la estabilidad del
modelo.




Ideal para ICFES

Extrae valor de la información
socioeconómica para apoyar mejores
predicciones.

CatBoost optimizado para un rendimiento superior

Una configuración equilibrada de hiperparámetros permite capturar patrones complejos en los datos socioeconómicos sin perder capacidad de generalización en la clasificación de quintiles académicos.



Depth 8

Controla la profundidad de cada árbol para capturar relaciones complejas sin aumentar demasiado la complejidad. Se eligió 8 como un punto medio eficiente entre capacidad predictiva y control del sobreajuste.



Iterations 150

Define la cantidad de rondas de boosting para refinar progresivamente el modelo. El valor 150 ofrece suficientes pasos para aprender patrones útiles sin prolongar innecesariamente el entrenamiento.



L2 Leaf Regularization 3

Actúa como penalización sobre los pesos de las hojas para estabilizar el aprendizaje. El valor 3 ayuda a reducir el sobreajuste y mejora la robustez del modelo.



Learning Rate 0.1

Controla el tamaño de cada actualización durante el entrenamiento. Un valor de 0.1 mantiene un aprendizaje gradual y equilibrado, favoreciendo una mejor generalización.

Cómo trabajan juntos estos parámetros

En conjunto, estos hiperparámetros equilibran complejidad, estabilidad y capacidad de generalización. Esto resulta especialmente útil en datos categóricos y socioeconómicos, donde CatBoost aprovecha la información disponible para producir predicciones más confiables de los quintiles académicos.

- ✓ La selección de estos valores busca maximizar la precisión del modelo manteniendo un comportamiento robusto frente al sobreajuste.

Resultados Generales

Crear una tabla comparativa completa con los resultados de los tres modelos. Resaltar visualmente los mejores valores (CatBoost en la mayoría de métricas):

Modelo	Accuracy	F1-Score	ROC-AUC	MAE	RMSE	Tiempo (s)
CatBoost 	0.3817	0.3685	0.7128	0.9636	1.3675	27093.61
XGBoost 	0.3801	0.3666	0.7119	0.9696	1.3747	9650.05
Random Forest 	0.3607	0.3281	0.6917	1.0949	1.5380	22332.14



CatBoost lidera en Accuracy, F1-Score y ROC-AUC.



XGBoost destaca por su menor tiempo de entrenamiento.



Random Forest muestra el desempeño más bajo en las métricas principales.

La sintonización precisa de estos hiperparámetros es fundamental para asegurar que el modelo XGBoost no solo alcance una alta precisión, sino que también mantenga una excelente capacidad de generalización a datos no vistos, evitando el sobreajuste y el subajuste para predecir los quintiles de desempeño académico.

Como se observa, CatBoost obtuvo el mejor desempeño en Accuracy, F1-Score, ROC-AUC, MAE y RMSE, aunque con un tiempo de entrenamiento más alto que XGBoost. La superioridad en métricas de precisión justifica el costo computacional adicional.

Comparación de Métricas de Clasificación

Para evaluar el rendimiento de cada modelo en la clasificación de quintiles académicos, se analizaron tres métricas clave: Accuracy, F1-Score y ROC-AUC. La siguiente comparación visual destaca las diferencias entre modelos:



Accuracy

CatBoost lidera con el mejor desempeño en precisión global.



F1-Score


CatBoost mantiene el equilibrio más sólido entre precisión y recall.




ROC-AUC

CatBoost también obtiene la mayor capacidad discriminativa.


Accuracy del Modelo



F1-Score del Modelo



ROC-AUC del Modelo





CatBoost

Mejor desempeño general en las tres métricas.



XGBoost

Resultados muy cercanos al líder, con gran estabilidad.



Random Forest

Desempeño inferior, aunque consistente.


Los gráficos de comparación demuestran claramente que **CatBoost** obtuvo el mejor desempeño general en las tres métricas de clasificación evaluadas: Accuracy, F1-Score y ROC-AUC. Esto resalta su superioridad en la capacidad discriminativa y predictiva para la clasificación de quintiles académicos dentro del dataset del ICFES. Su diseño para manejar variables categóricas de forma nativa contribuye a esta robustez y precisión en los resultados.

Análisis de Errores

Para profundizar en la evaluación del rendimiento de los modelos, analizamos dos métricas clave de error: el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE). Estos indicadores nos permiten comprender la magnitud de los errores de predicción y la dispersión de los mismos.


✓	⚠	✗
Azul Rey	Azul	Celeste
Menor error y mejor desempeño.	Desempeño intermedio o cercano.	Mayor error y peor desempeño.

Error Absoluto Medio (MAE)



El gráfico de MAE muestra que **CatBoost** presentó el menor error absoluto, lo que indica que sus predicciones están, en promedio, más cerca de los valores reales. **XGBoost** le sigue de cerca, mientras que **Random Forest** muestra un error significativamente mayor.

Raíz del Error Cuadrático Medio (RMSE)



Consistentemente, **CatBoost** mantiene los menores errores en ambas métricas, reflejando su capacidad superior para predecir los quintiles académicos con mayor exactitud.

Costo Computacional

El tiempo de entrenamiento es una métrica crucial para evaluar la eficiencia de un modelo, especialmente cuando se trabaja con grandes volúmenes de datos. A continuación, se presenta una comparación del tiempo que cada modelo tardó en ser entrenado:




Tiempo de entrenamiento

Evalúa cuánto tarda cada modelo en procesar y aprender a partir de los datos.



Recursos computacionales

Permite comparar la demanda de cómputo y el esfuerzo necesario para entrenar cada algoritmo.



Como se observa, **CatBoost** y **Random Forest** requieren significativamente más tiempo de entrenamiento que **XGBoost**. Aunque CatBoost demostró una precisión superior en las métricas predictivas clave, este rendimiento viene acompañado de un costo computacional más elevado.

Por otro lado, **XGBoost** ofrece un excelente balance entre velocidad y precisión, siendo una opción muy eficiente. La elección final del modelo debe considerar no solo su capacidad predictiva, sino también los recursos computacionales disponibles y las limitaciones de tiempo en el entorno real.

Interpretación de los Resultados

El análisis de los modelos de clasificación revela una fuerte relación entre las variables socioeconómicas y escolares, y el rendimiento académico de los estudiantes. Los tres modelos evaluados demuestran una capacidad predictiva significativa, con un valor de ROC-AUC consistentemente superior a 0.69, lo que valida la importancia de estas variables en la predicción de los quintiles de desempeño académico.



Variables Socioeconómicas

Ingresos familiares, educación de los padres y acceso a recursos básicos impactan de forma directa en el desempeño académico.



Variables Escolares

La institución educativa, los recursos pedagógicos y la calidad docente influyen considerablemente en los resultados.



Capacidad Predictiva

Los modelos confirman la validez de estas variables como predictores del rendimiento académico.



Ventaja de CatBoost

Destaca por maximizar la información disponible y manejar nativamente variables categóricas.

Conclusiones



CatBoost obtuvo el mejor desempeño global
Accuracy de 0.3817, F1-Score de 0.3685 y ROC-AUC de 0.7128.



XGBoost logró un balance muy sólido
Métricas muy cercanas a CatBoost con un tiempo de entrenamiento de solo 9650 segundos.



Random Forest mostró menor capacidad discriminativa
Presentó los menores valores en precisión y los mayores errores entre los modelos evaluados.



Variables socioeconómicas e institucionales
Tienen una relación significativa con el desempeño académico y ayudan a explicar el rendimiento estudiantil.



El rendimiento académico es multifactorial
No existe un único factor determinante: intervienen variables socioeconómicas, escolares y personales.



Trabajo futuro
Incorporar nuevas variables, aplicar SHAP y explorar ensemble más sofisticados.