

## Tablas

En este documento se busca organizar y maximizar la visión de las tablas presentes en el informe.

**Tabla 1. Hiperparámetros principales de Random Forest para clasificación.**

| Hiper Parámetro                    | Notación          | Rango típico                                | Efecto principal                                                                                  | Relevancia para la comparación                                                            |
|------------------------------------|-------------------|---------------------------------------------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| Número de árboles                  | n_estimators (T)  | 50–500<br>(común: 100)                      | Reduce la varianza y mejora la estabilidad al aumentar T; incrementa el costo computacional       | Valores bajos generan bajo desempeño; valores muy altos no aportan mejoras significativas |
| Número de características por nodo | max_features (m)  | $\sqrt{d}$ , $\log_2(d)$ , d, o entero fijo | Controla la aleatorización; menor m aumenta diversidad ( $\downarrow$ varianza, $\uparrow$ sesgo) | Clave distintiva frente a otros ensambles; mal ajuste genera árboles correlacionados      |
| Profundidad máxima                 | max_depth         | None o 10–30                                | Limita el crecimiento del árbol; menor profundidad reduce sobreajuste pero aumenta sesgo          | Permite controlar el balance sesgo-varianza frente a métodos como SVM                     |
| Mínimo de muestras por hoja        | min_samples_leaf  | 1–20 (común: 1, 2, 4)                       | Regula la complejidad; valores mayores generan modelos más suaves                                 | Útil ante ruido; valores bajos pueden causar sobreajuste                                  |
| Mínimo de muestras para dividir    | min_samples_split | 2–20 (común: 2, 5, 10)                      | Evita divisiones muy específicas; controla profundidad efectiva                                   | Afecta especialización de los árboles y su capacidad de generalización                    |
| Criterio de división               | criterion         | gini, entropy                               | Define la calidad de la división; Gini es más rápido, entropía más precisa                        | Diferencias pequeñas; importante mantener consistencia en experimentos                    |
| Bootstrap                          | bootstrap         | True, False                                 | Permite muestreo con reemplazo para cada árbol                                                    | Desactivarlo elimina la ventaja de reducción de varianza                                  |
| Peso de clases                     | class_weight      | None, balanced, personalizado               | Ajusta pesos para manejar desbalance de clases                                                    | Esencial en datasets desbalanceados para comparación justa                                |
| Semilla aleatoria                  | random_state      | Entero (ej. 42)                             | Garantiza reproducibilidad del modelo                                                             | Fundamental para comparaciones consistentes entre técnicas                                |

**Tabla 2. Hiper Parámetros principales de XGBoost para clasificación.**

| Hiperparámetro       | Notación                    | Rango típico | Efecto principal                                                                                                                                         | Relevancia para la comparación                                                                              |
|----------------------|-----------------------------|--------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| Número de árboles    | n_estimators                | 100 – 1000   | Define cuántos árboles componen el modelo. Más árboles pueden mejorar la precisión, pero aumentan el tiempo de entrenamiento y el riesgo de sobreajuste. | Permite comparar la complejidad y capacidad de aprendizaje frente a Random Forest y CatBoost.               |
| Tasa de aprendizaje  | learning_rate<br>( $\eta$ ) | 0.01 – 0.3   | Controla la contribución de cada árbol nuevo al modelo final. Valores bajos generan aprendizaje más estable y preciso.                                   | Fundamental para analizar la velocidad de convergencia y estabilidad del entrenamiento respecto a CatBoost. |
| Profundidad máxima   | max_depth                   | 3 – 12       | Limita la profundidad de cada árbol. Valores altos permiten capturar relaciones complejas, pero incrementan el sobreajuste.                              | Permite comparar la complejidad estructural de los árboles entre los distintos algoritmos.                  |
| Submuestreo de datos | subsample                   | 0.5 – 1.0    | Define la proporción de muestras utilizadas para entrenar cada árbol. Reduce correlación y sobreajuste.                                                  | Ayuda a evaluar la capacidad de generalización y robustez del modelo frente a Random Forest.                |

**Tabla 3. Hiper Parámetros principales de CatBoost para clasificación.**

| Hiperparámetro                  | Notación            | Rango típico                  | Efecto principal                                   | Relevancia para la comparación                                                           |
|---------------------------------|---------------------|-------------------------------|----------------------------------------------------|------------------------------------------------------------------------------------------|
| Número de iteraciones           | iterations          | 100–1000+                     | Número de árboles construidos secuencialmente      | Muy influyente en el rendimiento; demasiadas iteraciones pueden sobreajustar             |
| Tasa de aprendizaje             | learning_rate       | 0.01–0.3<br>(común: 0.03–0.1) | Controla la contribución de cada árbol             | Valores pequeños mejoran generalización pero requieren más iteraciones                   |
| Profundidad del árbol           | depth               | 4–10                          | Define la complejidad de los árboles               | Profundidades altas capturan relaciones complejas pero aumentan el riesgo de sobreajuste |
| Regularización L2               | l2_leaf_reg         | 1–10                          | Penaliza valores grandes en hojas                  | Reduce sobreajuste; clave frente a modelos no regularizados                              |
| Submuestreo                     | subsample           | 0.5–1.0                       | Proporción de datos usados por iteración           | Reduce varianza y mejora eficiencia                                                      |
| Temperatura de bagging          | bagging_temperature | 0–1                           | Controla el nivel de aleatorización en el muestreo | Mayor valor → más diversidad, menor riesgo de sobreajuste                                |
| Tipo de pérdida                 | loss_function       | Logloss, CrossEntropy         | Define la función objetivo                         | Debe ser consistente para comparaciones justas                                           |
| Manejo de clases                | class_weights       | None o lista/dict             | Ajusta pesos para clases desbalanceadas            | Esencial en datasets desbalanceados                                                      |
| Semilla aleatoria               | random_seed         | Entero (ej. 42)               | Controla la reproducibilidad del modelo            | Fundamental para comparaciones consistentes                                              |
| Manejo de variables categóricas | cat_features        | Índices/lista                 | Especifica variables categóricas                   | Ventaja clave de CatBoost frente a otros métodos                                         |

Justificación de hiperparámetros

Para la elección de los hiperparámetros, lo que se hizo fue crear 4 grupos de hiperparámetros que se entrenaban y validaban usando ten-cross-validation, luego se hallaba el F1 de dichos hiperparámetros y al tener el de los 4, se elegía el de mayor f1, esto se realizó para cada uno de los tres modelos y luego éstos se fijaban para realizar el entrenamiento de cada modelo con el total de los datos.

- RandomForest:

| max depth | max feature | min sample leaf | min sample split | n estimators |
|-----------|-------------|-----------------|------------------|--------------|
| 20        | sqrt        | 4               | 5                | 400          |

- XGBoost:

| learning rate | max depth | n estimators | subsample |
|---------------|-----------|--------------|-----------|
| 0.1           | 15        | 300          | 0.6       |

- CatBoost:

| depth | iterations | l2 leaf reg | learning rate |
|-------|------------|-------------|---------------|
| 8     | 150        | 3           | 0.1           |

Tabla de desempeño general de los métodos

| Modelo        | Accuracy  | F1-Score    | ROC-AUC    | MAE         | RMSE        | Tiempo (s) |
|---------------|-----------|-------------|------------|-------------|-------------|------------|
| CatBoost      | 0.3817069 | 0.368545055 | 0.71282861 | 0.963623859 | 1.367470563 | 27093.6125 |
| XGBoost       | 0.3801244 | 0.366604883 | 0.71191564 | 0.969551779 | 1.374724141 | 9650.04736 |
| Random Forest | 0.3606856 | 0.328132075 | 0.69171172 | 1.094947969 | 1.537977774 | 22332.1374 |

Elección de número de categorías:

Con el objetivo de analizar la estructura interna del conjunto de datos y determinar una segmentación adecuada de los estudiantes, se desarrolló un código que implementó el algoritmo K-Means junto con un algoritmo de agrupamiento jerárquico de aglomeración. Mediante el enfoque jerárquico se construyó el dendrograma, el cual permitió visualizar las relaciones de similitud entre los datos y analizar los posibles cortes para la formación de clusters. Posteriormente, se aplicó la técnica de la gráfica de codo (Elbow Method) sobre K-Means para identificar la cantidad óptima de agrupamientos. El análisis mostró un punto de inflexión representativo en (k = 12), adicionalmente se hizo un estudio estadístico básico donde pudimos observar la distribución de los datos en 12 categorías de igual tamaño, como se observa en la tabla, los extremos estaban muy poco poblados y los datos se concentraban en el medio, así que se decidió fusionar los extremos y aplicar quintiles, lo que nos generó 5 categorías que al realizarle el estudio nos dio la distribución de los datos de una forma casi equitativa, por lo que se determinó que cinco clusters constituían la mejor configuración para segmentar el dataset, además de que podría escoger los datos aleatoriamente tanto para el entrenamiento como para la validación y el test. Para este proceso se utilizaron aproximadamente 2,000,000 de registros del conjunto de datos del ICFES, permitiendo obtener resultados más robustos y representativos de los patrones presentes en la población estudiantil. Para ver el código sobre los cluster, revisar el repositorio de Github.





Tabla de distribución de datos en categorías.


| Análisis estadístico básico para 12 categorías                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | Análisis estadístico básico para 5 categorías                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>===== ESTADÍSTICAS BÁSICAS =====<br/>count 3.308074e+06<br/>mean 2.504597e+02<br/>std 5.168630e+01<br/>min 0.000000e+00<br/>25% 2.110000e+02<br/>50% 2.470000e+02<br/>75% 2.870000e+02<br/>max 5.000000e+02<br/>Varianza: 2671.4739<br/>Asimetría: 0.3146<br/>Curtosis: -0.3942<br/><br/>===== CONTEO POR CATEGORÍA =====<br/><br/>Categoría 0: 220 registros (0.01%)<br/>Categoría 1: 90 registros (0.00%)<br/>Categoría 2: 720 registros (0.02%)<br/>Categoría 3: 99870 registros (3.02%)<br/>Categoría 4: 681024 registros (20.59%)<br/>Categoría 5: 958263 registros (28.97%)<br/>Categoría 6: 823483 registros (24.89%)<br/>Categoría 7: 526375 registros (15.91%)<br/>Categoría 8: 190254 registros (5.75%)<br/>Categoría 9: 25478 registros (0.77%)<br/>Categoría 10: 2167 registros (0.07%)<br/>Categoría 11: 130 registros (0.00%)</div> | <div>===== ESTADÍSTICAS BÁSICAS =====<br/>count 3.308074e+06<br/>mean 2.504597e+02<br/>std 5.168630e+01<br/>min 0.000000e+00<br/>25% 2.110000e+02<br/>50% 2.470000e+02<br/>75% 2.870000e+02<br/>max 5.000000e+02<br/>Varianza: 2671.4739<br/>Asimetría: 0.3146<br/>Curtosis: -0.3942<br/><br/>===== CONTEO POR CATEGORÍA =====<br/><br/>Categoría 0: 677200 registros (20.47%)<br/>Categoría 1: 671569 registros (20.30%)<br/>Categoría 2: 654915 registros (19.80%)<br/>Categoría 3: 660111 registros (19.95%)<br/>Categoría 4: 644279 registros (19.48%)</div> |

Matrices de confusión:

- CatBoost:



● **RandomForest:**



● **XGBoost:**

